

Master 1- Econométrie et statistiques

Étude et prévision des ventes de véhicules aux États-Unis

Dossier de techniques de prévision et conjoncture, réalisé par :
Tijou Louane
Abouzayd Ikram

Sous la supervision de Monsieur Darné

Sommaire

1) Introduction.....	3
2) Analyse exploratoire.....	5
2.1 Identification et analyse économique des points atypiques.....	5
2.2 Statistiques descriptives de la série corrigée.....	6
2.3 Détection de la saisonnalité.....	8
2.4 Désaisonnalisation et décomposition de la série corrigée.....	9
3) Prévion de la série saisonnière.....	10
3.1 Estimations et prévisions des modèles.....	10
i) Les méthodes Naïve, X13-SARIMA-SEATS, STL et STS.....	10
ii) Les méthodes de lissage exponentiel.....	11
3.2 Tableau récapitulatif et comparaison des modèles basée sur l'AIC et l'AICc.....	14
4) Evolution des prévisions des différents modèles.....	15
5) Qualité de prévision.....	16
6) Test de précision.....	18
7) Conclusion.....	19
8) Annexes.....	20


1) Introduction

Dans ce dossier, la série étudiée porte sur les ventes totales de véhicules aux États-Unis. Il s'agit de la série "Total Vehicle Sales" (TOTALNSA), extraite de la base FRED de la Federal Reserve Bank of St. Louis, dont la source d'origine est le U.S. Bureau of Economic Analysis (BEA). Cette série est mensuelle, exprimée en milliers d'unités, et couvre la période allant de janvier 2006 à décembre 2025, soit 20 années de données. Comme il s'agit d'une série non désaisonnalisée, les variations saisonnières sont encore présentes dans les observations.

Cette série est intéressante car les ventes de véhicules réagissent fortement aux évolutions de l'économie. Elles dépendent notamment du pouvoir d'achat des ménages, de leur confiance dans l'avenir, ainsi que des conditions d'accès au crédit. Lorsque la situation économique se dégrade, les ménages ont tendance à repousser l'achat d'une voiture, car il s'agit d'une dépense importante. À l'inverse, quand le contexte s'améliore, les ventes repartent généralement à la hausse. Cette série permet ainsi de bien mettre en évidence les phases de ralentissement et de reprise de l'activité.

Afin d'avoir une première vue d'ensemble, il est utile d'observer l'évolution de la série sur l'ensemble de la période étudiée.

Graphique 1 : Ventes de véhicules aux Etats-Unis




À la lecture du **Graphique 1**, la série évolue de façon irrégulière sur l'ensemble de la période, tout en laissant apparaître certaines régularités, avec des fluctuations qui semblent se répéter dans le temps. Les ventes alternent ainsi entre des phases de baisse, de reprise et de ralentissement, ce qui reflète leur sensibilité au contexte économique.

Certains épisodes ressortent déjà visuellement, notamment autour de 2008-2009 et de 2020. Toutefois, ces variations ne sont pas développées ici, puisqu'elles feront l'objet d'une analyse plus précise dans la section consacrée à la détection des points atypiques.

Au-delà de l'évolution globale de la série, il est également pertinent d'observer si certains mouvements se reproduisent de façon régulière d'une année à l'autre. Le **Graphique 2** saisonnier ci-dessous permet de mieux visualiser cette régularité.

Graphique 2 : Évolution de la saisonnalité de la série brute d'une année à l'autre



En observant ce graphique, on retrouve un profil assez similaire selon les périodes. Les ventes sont généralement plus faibles en janvier et en février. Le début d'année semble donc moins favorable à l'achat de véhicules. Cela peut s'expliquer par le fait que les ménages ont souvent déjà eu beaucoup de dépenses en fin d'année, notamment pendant les fêtes, et préfèrent donc reporter ce type d'achat.

À partir du mois de mars, les ventes augmentent généralement. Cette période peut être plus favorable aux achats de véhicules, notamment avec l'arrivée du printemps, les offres commerciales ou le renouvellement de certains modèles. Les ventes restent ensuite assez élevées entre le printemps et l'été, même si elles varient selon les années.

En fin d'année, le mois de décembre ressort également comme une période plus dynamique. Cette hausse peut s'expliquer par plusieurs facteurs, comme les promotions de fin d'année, les objectifs commerciaux des concessionnaires, ou encore les achats réalisés avant les fêtes et les départs en vacances. La période de Noël peut aussi encourager certains ménages à renouveler leur véhicule ou à avancer un achat prévu.

Cependant, toutes les années ne présentent pas exactement le même profil. Certaines périodes, comme 2008-2009 ou 2020, se distinguent par des niveaux de ventes plus faibles. Cela montre que les habitudes saisonnières peuvent être modifiées par des événements économiques importants. Malgré ces différences, le graphique laisse penser qu'il existe bien une saisonnalité dans les ventes de véhicules.

2) Analyse exploratoire

2.1 Identification et analyse économique des points atypiques

Afin d'obtenir des prévisions fiables, il est important de vérifier la présence éventuelle de points atypiques dans la série temporelle. Dans notre cas, quatre points atypiques ont été identifiés :

Tableau 1 : Points atypiques et ruptures détectés dans la série

Type	Date	Coefficient	t-stat
AO	Août 2009	317.5	5.5
TC	Mars 2020	-589.8	-9.31
AO	Avril 2020	-285.4	-4.76
LS	Août 2021	-267.3	-4.38

Parmi les quatre anomalies détectées (voir Graphique 3 en annexe), nous nous concentrons ici sur les trois principales.

En août 2009, on identifie un point atypique ponctuel positif (*Additive Outlier*), qui correspond à une hausse des ventes sur une courte période. Ce rebond s'explique par les mesures de relance mises en place après la crise financière de 2008. Le programme « Cash for Clunkers », par exemple, incitait les ménages à remplacer leur ancien véhicule par un modèle plus récent, en échange d'une aide financière. Ce type de dispositif a encouragé les achats sur une période limitée, ce qui se reflète dans la série.

En mars 2020, on observe un choc temporaire (*Temporary Change*), avec une forte baisse des ventes, puis une remontée progressive qui ramène la série vers son niveau habituel. Cette évolution correspond au début de la crise du Covid-19. Les mesures de confinement ont fortement limité les déplacements et fermé de nombreux points de vente, ce qui a freiné les achats. À cela s'ajoutent un climat d'incertitude et une baisse de confiance des ménages, qui ont conduit à reporter les dépenses importantes comme l'achat d'un véhicule. Du côté de l'offre, la production automobile a également été perturbée. En avril 2020, on observe en plus un choc ponctuel (*Additive Outlier*), qui accentue cette baisse sur un mois précis. L'ensemble de cette période traduit donc un recul très marqué mais temporaire des ventes.

Enfin, en août 2021, on observe un changement de niveau (*Level Shift*), c'est-à-dire une modification plus durable du niveau des ventes. Cette évolution s'explique notamment par les difficultés d'approvisionnement dans le secteur automobile, en particulier la pénurie de semi-conducteurs. Ces composants étant essentiels à la fabrication des véhicules, leur

manque a ralenti la production et limité l'offre disponible. Contrairement aux autres épisodes, l'effet est ici plus persistant, ce qui explique la rupture observée dans la série.

2.2 Statistiques descriptives de la série corrigée

Une fois la série corrigée des points atypiques, on peut regarder ses principales caractéristiques statistiques pour mieux comprendre sa distribution.

Tableau 2 : Statistiques descriptives de la série corrigée

Statistique	Valeur
Nombre d'observations	240
Valeurs manquantes	0
Minimum	670.47
Maximum	1898.89
Moyenne	1367.02
Médiane	1408.54
Variance	61107.23
Écart-type	247.2
Skewness	-0.63

La série corrigée comporte 240 observations et ne présente aucune valeur manquante, ce qui permet de travailler sur une base complète.


Comme nous l'avons vu précédemment, les ventes évoluent de façon assez irrégulière au cours du temps. Les statistiques descriptives confirment cette observation : la moyenne s'établit à 1367,02, alors que la médiane est légèrement plus élevée, à 1408,54. Cela montre que certaines périodes de ventes plus faibles tirent légèrement le niveau moyen vers le bas.

La dispersion est également assez marquée. L'écart-type atteint 247,2, avec un minimum de 670,47 et un maximum de 1898,89. L'écart entre ces deux valeurs reste important, ce qui confirme que la série ne varie pas autour d'un niveau stable, mais connaît au contraire des phases plus contrastées.

La skewness est de -0,63. Cela indique une légère asymétrie vers la gauche : les baisses de ventes sont donc plus marquées que les hausses exceptionnelles. Cela rejoint ce que l'on observait déjà sur le **Graphique 1**.

Enfin, la kurtosis est de -0,07, une valeur proche de zéro. Cela signifie qu'après correction des points atypiques, la distribution reste assez équilibrée, sans concentration trop forte de valeurs extrêmes.

Graphique 4 : Distribution de la série corrigée



Le boxplot présenté ci-dessus confirme cette analyse. La majorité des observations se situe autour d'un niveau central assez élevé, avec une médiane proche de 1400. On observe néanmoins une valeur particulièrement basse qui rappelle qu'un épisode de forte chute des ventes reste visible dans la série, même après correction.

Dans l'ensemble, la série corrigée reste assez variable. Les baisses ressortent davantage que les fortes hausses, ce qui montre que les ventes de véhicules aux États-Unis réagissent fortement aux changements de contexte économique.


2.3 Détection de la saisonnalité

Après l'analyse descriptive, il est utile de vérifier plus précisément si les variations observées au fil du temps suivent aussi un rythme régulier au cours de l'année.

Comme le montrent les **Graphiques 5 et 6** en annexe, les variations de la série ne s'expliquent pas uniquement par la tendance générale ou par quelques chocs ponctuels. La décomposition additive permet de mieux distinguer ces éléments. On observe une tendance qui baisse jusqu'en 2009, puis qui repart progressivement à la hausse. La composante saisonnière est également bien visible : elle se répète assez régulièrement d'une année à l'autre, avec des variations qui reviennent aux mêmes périodes. Cela montre que certains mois sont plus favorables aux ventes que d'autres. Enfin, la composante aléatoire reste présente, ce qui signifie qu'une partie des variations mensuelles dépend encore d'éléments plus ponctuels ou imprévisibles.

Ce résultat est également confirmé par le périodogramme de la série en différence première présenté ci-dessous.

Graphique 7 : Périodogramme de la série en différence première



On y observe plusieurs pics marqués, notamment autour des fréquences 0,25, 0,33 et surtout 0,42, ce qui montre que les fluctuations de la série ne sont pas uniquement irrégulières. Une partie des mouvements suit donc un rythme récurrent, ce qui renforce l'idée d'une saisonnalité bien présente dans la série.

Le tableau des tests permet ensuite de confirmer ce résultat de manière plus formelle.

Tableau 3 : Résultats des tests de saisonnalité de la série

Test de saisonnalité				Test de Log-Level
Webel-Ollech		Seasonal dummies		
stat	p-value	stat	p-value	
1	0	72,23	0	NONE

Le test de Webel-Ollech et le test seasonal dummies donnent tous les deux des p-values nulles. On rejette donc l'hypothèse d'absence de saisonnalité. On retrouve ainsi, dans les tests statistiques, ce que l'on observait déjà dans les graphiques : les évolutions mensuelles ne dépendent pas seulement de la conjoncture, mais aussi d'effets qui se répètent selon les mois.

Au final, l'ensemble des résultats conduit à la même conclusion : la série présente bien une saisonnalité significative, régulière et identifiable, qu'il faudra donc prendre en compte dans la suite de l'analyse.

2.4 Désaisonnalisation et décomposition de la série corrigée

Afin d'aller plus loin dans l'analyse, la série corrigée des points atypiques a été désaisonnalisée à l'aide de la méthode X13-ARIMA-SEATS. Cette étape permet de retirer les effets saisonniers afin de mieux observer l'évolution des ventes au cours du temps.

Le test log-level (**Tableau 3**) indique "NONE", ce qui signifie qu'aucune transformation logarithmique n'est nécessaire. La série est donc conservée en niveau, ce qui correspond à une décomposition additive. Ce choix est cohérent avec ce qui a été observé précédemment puisque l'amplitude des variations saisonnières reste globalement stable sur la période.

La procédure X13 retient un modèle RegARIMA de type SARIMA(0,1,1)(1,1,1)₁₂. Cela signifie qu'une différenciation simple et une différenciation saisonnière ont été nécessaires ($d = 1$ et $D = 1$), ce qui confirme que la série n'était pas stationnaire au départ. Le terme de moyenne mobile d'ordre 1 ($q = 1$) indique que les ventes actuelles sont influencées par les chocs aléatoires du mois précédent, traduisant une persistance des imprévus à court terme. La composante saisonnière indique également que les ventes restent liées aux évolutions observées aux mêmes périodes les années précédentes.

Les coefficients estimés sont tous significatifs. En particulier, le coefficient saisonnier BTheta(1) égal à -0,99998 et donc très proche de -1, met en évidence une saisonnalité forte et persistante dans la série. Cela confirme les observations faites lors de l'analyse graphique.

Le modèle prend aussi en compte des effets calendaires. Certains jours de la semaine, comme le lundi et surtout le samedi, ont un impact significatif sur les ventes. Cela peut s'expliquer par les habitudes de consommation, avec une fréquentation plus importante des concessions en fin de semaine. L'effet des années bissextiles est également significatif, ce qui montre que la structure du calendrier influence légèrement le niveau des ventes. En revanche, aucun effet lié à Pâques n'a été retenu.

Par ailleurs, plusieurs points atypiques restent significatifs dans le modèle. Ils correspondent aux périodes déjà identifiées, notamment la crise de 2008-2009, le choc lié au Covid-19 en 2020, ainsi que les perturbations du secteur automobile à partir de 2021. Leur prise en compte permet d'éviter qu'ils ne biaisent l'estimation de la saisonnalité.

Enfin, les graphiques de décomposition présentés en annexe (**Graphiques 8 et 9**) montrent qu'une fois la saisonnalité retirée, la série désaisonnalisée devient plus lisible que la série brute. Les principales phases d'évolution des ventes apparaissent alors plus clairement, notamment les périodes de baisse, de reprise et de ralentissement.

Dans l'ensemble, la méthode X13-ARIMA-SEATS semble bien adaptée à cette série. Elle permet de mieux comprendre l'évolution des ventes en distinguant les effets de tendance, de saisonnalité, de calendrier et les chocs exceptionnels.

3) Prédiction de la série saisonnière

3.1 Estimations et prévisions des modèles

i) Les méthodes Naïve, X13-SARIMA-SEATS, STL et STS.

Dans un premier temps, nous avons réalisé des prévisions sur 12 mois à partir des méthodes naïves saisonnières, X13-SARIMA-SEATS, STL et STS. Ces premières approches permettent d'obtenir une première lecture des trajectoires prévues pour l'année 2025, avant de comparer plus précisément leurs performances.

Dans ce cadre, le modèle X13-SARIMA-SEATS retient une spécification SARIMA(0,1,1)(1,1,1)₁₂, ce qui confirme la présence d'une tendance et d'une saisonnalité dans la série. Aucune transformation logarithmique n'est retenue, ce qui montre bien que la série est modélisée en niveau, dans un cadre plutôt additif. Les résultats obtenus sont globalement satisfaisants, ce qui suggère que le modèle reproduit correctement les principaux mouvements de la série.

Le modèle STS permet de distinguer les différentes composantes de la série. Ici, la variance du niveau est la plus élevée (2215,204), ce qui montre que les ventes varient surtout à travers des changements du niveau général. La variance de la pente est beaucoup plus faible (2,895), ce qui signifie que la tendance évolue lentement dans le temps. La composante saisonnière reste présente, avec une variance de 728,462, ce qui confirme que les ventes suivent encore un rythme saisonnier. Enfin, la variance de l'erreur (1289,577) indique qu'une partie des variations reste liée à des mouvements plus irréguliers. Le **Graphique 10** en annexe confirme cette lecture, avec une trajectoire globalement régulière et des zones grisées qui s'élargissent progressivement, traduisant une incertitude plus forte à mesure que l'horizon de prévision augmente.

ii) Les méthodes de lissage exponentiel

a) Holt-Winters

Nous avons d'abord estimé le modèle de Holt-Winters, retenu en raison du caractère saisonnier de la série. Dans notre cas, la spécification additive a été privilégiée, conformément aux résultats observés précédemment.

Les paramètres de lissage estimés indiquent une forte réactivité du modèle aux nouvelles observations. En effet, la composante de niveau, soit le paramètre alpha (0,42) indique que le modèle accorde un poids modéré aux observations récentes, ainsi il prend en compte les nouvelles observations sans changer complètement les prévisions. La composante de tendance quant à elle (beta (0,01)) , est très faible, cela signifie que les nouvelles informations ont peu d'impact sur l'estimation de la tendance (fort poids des

valeurs lointaines), le modèle semble ainsi avoir une tendance qui évolue peu dans le temps et relativement stable et donc peu volatile. Enfin la composante saisonnière caractérisée par le paramètre gamma (0,33) indique que la composante saisonnière est ajustée de manière progressive. Le modèle prend en compte les variations saisonnières tout en conservant une certaine stabilité dans leur structure.

Le **Graphique 11** en annexe montre que les prévisions du modèle suivent globalement la tendance et la saisonnalité de la série, mais avec une évolution plus lissée. En raison de ce lissage, les variations les plus marquées sont davantage atténuées, ce qui peut limiter la capacité du modèle à restituer fidèlement certains mouvements de la série. Par ailleurs, les intervalles de confiance (en gris) s'élargissent au fur et à mesure, ce qui montre que les prévisions deviennent de plus en plus incertaines quand on s'éloigne dans le temps.

b) ETS

Nous avons ensuite estimé le modèle ETS. Le modèle retenu est de type ETS(A,N,A), ce qui indique qu'il repose sur une erreur additive, sans tendance, et avec une saisonnalité additive.

Le paramètre de lissage alpha (0,48) indique là encore un poids assez proche à la fois sur les valeurs passé et récent de la série. En revanche, l'absence de composante de tendance (N) indique que le modèle ne retient pas de dynamique de croissance ou de décroissance marquée à long terme.

Par ailleurs, le paramètre gamma, très proche de zéro, suggère que la saisonnalité reste globalement très stable dans le temps. Cela signifie aussi que le modèle réagit peu aux nouvelles variations saisonnières et met donc plus de temps à s'ajuster lorsqu'un changement apparaît.

Enfin, le **Graphique 12** en annexe montre, comme pour le modèle de Holt-Winters, que les prévisions suivent dans l'ensemble la dynamique générale de la série en reproduisant les effets saisonniers. Toutefois, la trajectoire reste assez lissée et les intervalles de confiance s'élargissent progressivement, ce qui montre une incertitude plus forte à mesure que l'horizon de prévision s'allonge.

c) Modèle TBATS

Le modèle retenu par la méthode TBATS est de type TBATS(1, (0,0), -, (12,5)). Il inclut une transformation de Box-Cox, mais ne retient ni composante ARMA dans les résidus, ni tendance amortie. En revanche, il prend bien en compte la saisonnalité de la série, avec une périodicité de 12 mois modélisée à l'aide de 5 termes trigonométriques.

On retrouve une nouvelle fois un paramètre de lissage alpha assez proche des autres modèles de lissage exponentiel estimé de 0,46, indiquant que le modèle accorde un poids modéré aux observations récentes.

À l'inverse, les paramètres associés à la saisonnalité (γ), sont très proches de zéro. Ils montrent que la prévision est globalement stable dans le temps et peu modifiée par les nouvelles données.

Concernant le **Graphique 13** en annexe, les conclusions sont là encore les mêmes que pour les modèles précédents.

d) ADAM ETS

Le modèle estimé avec la méthode ADAM combine automatiquement une structure ETS(A,N,A) et un modèle SARIMA(3,0,0)(3,0,0)₁₂. Il permet donc de prendre en compte à la fois la saisonnalité de la série et sa dynamique autorégressive.

La partie ETS(A,N,A) correspond, comme pour le modèle ETS précédent, à une erreur additive, sans tendance, avec une saisonnalité additive. Les paramètres de lissage montrent que le modèle réagit de façon modérée aux nouvelles observations. Le paramètre α (0,44) indique que les valeurs récentes ont un poids important, sans pour autant écraser complètement les valeurs passées. De son côté, γ (0,15) montre que la saisonnalité évolue peu dans le temps, même si elle est un peu moins rigide que dans le modèle ETS simple.

Pour la partie SARIMA, le modèle retient une composante autorégressive, à la fois sur la partie non saisonnière et sur la partie saisonnière, avec trois termes AR, sans différenciation ni composante moyenne mobile. Cela lui permet de mieux tenir compte de la dépendance entre les observations au cours du temps.

Par ailleurs, les critères d'information obtenus, notamment l'AIC (2607,6) et l'AICc (2608,6), sont plus faibles que ceux des autres modèles de lissage exponentiel étudiés auparavant. Cela montre que l'ajout de la composante SARIMA améliore l'ajustement du modèle. Ce modèle est donc intéressant, car il combine les avantages du lissage exponentiel et ceux des modèles ARIMA, ce qui lui permet de mieux représenter la dynamique de la série.

Enfin, le **Graphique 14** en annexe montre que le modèle ADAM ETS suit bien la série observée sur la période d'estimation. Les prévisions restent dans la continuité des évolutions passées et semblent mieux reproduire les variations de court terme que les modèles présentés précédemment.

e) ADAM ETS + ARIMA

Le modèle estimé avec la méthode ADAM associe une structure ETS(AAdA) à un modèle SARIMA(3,2,3)(3,0,3)₁₂. Il permet ainsi de prendre en compte à la fois la saisonnalité, la tendance et les dépendances temporelles de la série.

Les paramètres de lissage sont faibles. α (0,02) et β (0,003), très proches de zéro, montrent que le modèle réagit peu aux nouvelles observations. Il s'appuie donc

d'avantage sur les informations passées. Le paramètre gamma (0,17) indique, de son côté, que la saisonnalité est ajustée dans le temps, mais de façon limitée.

La présence d'un paramètre de damping (0,98) traduit une tendance amortie. Autrement dit, la tendance est bien prise en compte, mais son effet a tendance à se réduire progressivement à long terme.

La partie SARIMA comprend plusieurs termes autorégressifs et de moyenne mobile. Cela permet au modèle de mieux capter les liens entre les observations, aussi bien à court terme qu'au niveau saisonnier.

Les critères d'information, en particulier l'AIC (2616) et l'AICc (2619), montrent que le modèle s'ajuste bien à la série, même s'il est un peu moins performant que le modèle précédent.

Enfin, le **Graphique 15** en annexe est très proche de celui du modèle ADAM ETS. Les prévisions suivent presque la même dynamique et prolongent de façon cohérente les évolutions récentes de la série. Cette proximité s'explique par le fait que les deux modèles reposent sur une logique assez proche, en combinant un lissage exponentiel et une composante autorégressive, ce qui conduit à des résultats similaires.

3.2 Tableau récapitulatif et comparaison des modèles basée sur l'AIC et l'AICc

Tableau 5 : Récapitulatif des modèles

Modèle	ETS (A,N,A)	ADAM ETS(A,N,A)+ SARIMA(3,0,0) (3,0,0) ₁₂	ADAM ETS(A,Ad,A) + SARIMA(3,2,3) (3,0,3) ₁₂	SSARIMA (3,1,2) [1](2,0,0) ₁₂	SARIMA (3,1,1) (0,1,2) ₁₂	TBATS (1, (0,0), _)
Alpha	0.4766	0.4374	0,0157	-	-	-
Beta	-	-	0,003	-	-	-
Gamma	0,0001	0.1470	0,1704	-	-	-
phi	-	-	0,9846	-	-	-
Lambda	-	-	-	-	-	0.4554
AR1	-	0,0087	-1,0744	-1,1109	-1,4681	-
AR2	-	-0,0352	-0,6374	-0,4416	-0,8546	-
AR3	-	0,2453	-0,0524	0,0071	-0,2284	-

SAR1	-	0,0429	-0,0146	0,5867	-	-
SAR2	-	-0,1264	-0,1048	0,2691	-	-
SAR3	-	-0,1499	-0,7531	-	-	-
MA1	-	-	-0,4073	0,4983	0,9538	-
MA2	-	-	-0,4497	-0,2738	-	-
MA3	-	-	-0,1182	-	-	-
SMA1	-	-	0,1752	-	-0,6902	-
SMA2	-	-	0,0752	-	-0,174	-
SMA3	-	-	0,6912	-	-	-
Distribution	Normale additive	Normale généralisée	Normale	Normale	-	-
AIC	3224,82	2607,57	2616,05	2674,33	2476,66	3236,46
AICc	3227,1	2608,6	2618,9	2674,9	2477,2	-


D'après ce tableau récapitulatif, le meilleur modèle selon les critères AIC et AICc est le SARIMA(3,1,1)(0,1,2)₁₂, avec les valeurs les plus faibles : AIC = 2476,66 et AICc = 2477,20. Il offre donc le meilleur compromis entre la qualité d'ajustement et la complexité du modèle.

La différence avec les autres modèles est assez importante. Par exemple, le modèle ayant le plus mauvais AIC est le TBATS, avec 3236,46, soit un écart d'environ 759,8 points par rapport au SARIMA retenu. Pour l'AICc, le moins bon modèle est ETS(A,N,A) avec 3227,10, soit environ 749,9 points de plus que le meilleur modèle. Ces écarts montrent que le SARIMA choisi est nettement plus performant selon ces critères.

Il est aussi intéressant de noter que le SARIMA fait mieux qu'un modèle plus simple comme ETS(A,N,A), mais également mieux que des modèles plus complexes comme les modèles ADAM. Par exemple, ADAM ETS(A,N,A)+SARIMA(3,0,0)(3,0,0)₁₂ a un AIC de 2607,57, soit environ 130,91 points de plus que le SARIMA. Cela montre que le modèle le plus simple n'est pas forcément suffisant, mais qu'ajouter davantage de paramètres n'améliore pas automatiquement l'ajustement. Dans notre cas, une structure SARIMA apparaît donc comme la plus adaptée selon les critères AIC et AICc.

4) Evolution des prévisions des différents modèles

Graphique 16 : Evolution des prévisions selon les différentes méthodes (2025)



La plupart des modèles proposent des prévisions assez proches pour l'année 2025. Ils reprennent globalement les principaux mouvements de la série réalisée, représentée en rouge : une hausse en début d'année, une baisse au printemps, une reprise en été, puis un nouveau recul avant la remontée de fin d'année. Cela montre que la saisonnalité générale est assez bien prise en compte par la majorité des méthodes.

Cependant, on remarque que la série réalisée varie davantage que les prévisions. La courbe rouge présente des mouvements plus marqués, alors que plusieurs modèles donnent des trajectoires plus lissées. La méthode naïve, en noir, est celle qui s'éloigne le plus, notamment autour de septembre où elle prévoit une baisse plus forte que celle observée. Le modèle X13-SARIMA-SEATS, en orange, se distingue aussi au printemps, avec une prévision plus élevée que la série réelle. Le modèle STS, en vert, surestime également certaines périodes, surtout autour de l'été.

À l'inverse, les modèles ETS, TBATS, SARIMA, ADAM ETS et Holt-Winters restent souvent plus proches les uns des autres et suivent de manière assez similaire l'évolution générale des ventes. Cependant, sur une grande partie de la période, leurs prévisions sont légèrement supérieures aux valeurs réellement observées, ce qui traduit une tendance à la surestimation.

Ainsi, ce graphique permet d'avoir une première comparaison visuelle, mais il ne suffit pas à désigner le meilleur modèle. Il doit être complété par des indicateurs de précision afin de comparer les performances de manière plus fiable.

5) Qualité de prévision

Tableau 6 : Mesures d'erreur de prévision pour les différents modèles estimés

Modèle	MSE	R ² OOS
X13-ARIMA-SEATS	8258,02	-0,2116
STL	3921,80	0,4246
STS	8858,14	-0,2997
Holt-Winters	4926,99	0,2771
ETS	4104,30	0,3978
TBATS	4104,46	0,3978
ADAM ETS	4372,93	0,3584
ADAM ETS + ARIMA	10169,55	-0,4921
SSARIMA	12819,33	-0,8808
SARIMA	7323,79	-0,0745
Naïve	6815,78	NA (benchmark)


À partir du tableau des erreurs de prévision ci-dessus, on observe que le modèle le plus performant est STL. Il présente la MSE la plus faible (3921,80), ce qui signifie qu'il réduit davantage l'erreur quadratique moyenne sur l'échantillon de test. Il est ensuite suivi par les modèles ETS (4104,30) et TBATS (4104,46), dont les performances restent très proches et globalement satisfaisantes.

Ce constat se confirme avec le R²OOS. Les modèles STL, ETS, TBATS, ADAM ETS et Holt-Winters affichent tous un R²OOS positif, ce qui montre qu'ils offrent de meilleures prévisions que la méthode naïve saisonnière. Parmi eux, STL se distingue une nouvelle fois avec le R²OOS le plus élevé (0,4246). Autrement dit, il permet de diminuer l'erreur de prévision d'environ 42 % par rapport au modèle de référence naïf.

À l'inverse, les modèles X13-SARIMA-SEATS, STS, SARIMA, ADAM ETS + ARIMA et surtout SSARIMA obtiennent un R²OOS négatif, ce qui traduit des résultats moins bons que ceux de la méthode naïve. Le modèle SSARIMA est d'ailleurs le moins performant, avec la MSE la plus élevée (12819,33) et le R²OOS le plus faible (-0,8808).

Pour compléter l'analyse du tableau, le graphique de CSPE ci-dessous permet d'observer plus précisément la manière dont les erreurs se cumulent au fil des mois selon les modèles.

Graphique 17 : Erreur quadratique cumulative (CSPE) par modèle



On retrouve visuellement que STL fait partie des modèles les plus performants : sa courbe de CSPE reste parmi les plus basses presque tout au long de la période. Cela confirme les résultats du tableau précédent, où STL obtenait la MSE la plus faible et le R^2_{OOS} le plus élevé. Les modèles ETS et TBATS suivent une trajectoire assez proche, ce qui montre qu'ils donnent eux aussi de bonnes prévisions. Toutefois, cette bonne performance prédictive doit être nuancée : dans le tableau des AIC et AICc, ETS et TBATS sont parmi les modèles les moins bien classés. Ils prévoient donc bien sur la période de test, même s'ils ne sont pas les meilleurs en termes d'ajustement aux données passées.

À l'inverse, SSARIMA se distingue par une courbe de CSPE beaucoup plus élevée que les autres, surtout lorsque l'horizon de prévision s'allonge. Cela signifie que ses erreurs s'accumulent plus rapidement, ce qui confirme sa faible performance dans le tableau des indicateurs, avec la MSE la plus élevée et un R^2_{OOS} très négatif. ADAM ETS + ARIMA apparaît lui aussi moins performant, avec une hausse importante de l'erreur cumulée en fin de période.

Ces résultats montrent que le classement des modèles varie selon le critère retenu. Le modèle SARIMA, qui était le meilleur selon l'AIC et l'AICc, ne ressort pas comme le meilleur en prévision. À l'inverse, ETS et TBATS sont moins bien classés selon les critères d'ajustement, mais restent proches de STL en termes d'erreurs de prévision. Cela montre qu'un bon ajustement aux données passées ne garantit pas forcément une meilleure capacité prédictive sur la période de test.

Enfin, on remarque qu'au début de la période, plusieurs courbes restent assez proches, ce qui suggère que les différences entre modèles sont encore limitées sur les premiers mois. En revanche, les écarts deviennent plus visibles au fil du temps : certains modèles accumulent lentement les erreurs, tandis que d'autres les accumulent beaucoup plus rapidement. Les différences de qualité de prévision apparaissent donc surtout lorsque l'horizon de prévision s'allonge.

6) Test de précision

Tableau 7 : Résultats du test de Diebold-Mariano

Modèle	DM_stat	p_value
AR(1)	benchmark	
Naïve	-5.0985	2,00E-04
Holt-Winters	-4.9190	2,00E-04
ADAM ETS	-4.9297	2,00E-04
X13-SARIMA-SEATS	-4.7954	3,00E-04
STL	-4.8616	3,00E-04
ETS	-4.8321	3,00E-04
TBATS	-4.8328	3,00E-04
SARIMA	-4.5835	4,00E-04
STS	-4.4081	5,00E-04
ADAM ETS + ARIMA	-4.4048	5,00E-04
SSARIMA	-4.0062	1,00E-03

Le test de Diebold-Mariano compare la précision des modèles à un modèle de référence, ici AR(1), utilisé comme benchmark, d'où l'absence de statistique et de p-value pour celui-ci.

L'ensemble des statistiques DM est négatif et les p-values sont toutes très faibles (inférieures à 1 %), ce qui conduit à rejeter l'hypothèse nulle d'égalité de précision prédictive. Cela signifie que tous les modèles testés présentent des erreurs de prévision significativement plus faibles que le modèle AR(1).

Parmi les modèles comparés, la prévision naïve, Holt-Winters et ADAM ETS obtiennent les statistiques DM les plus faibles en valeur, ce qui suggère une amélioration plus importante par rapport au modèle AR(1). À l'inverse, SSARIMA présente la statistique la moins éloignée de zéro, même si son avantage reste statistiquement significatif.

Ces résultats montrent donc que l'ensemble des méthodes retenues surperforme le modèle AR(1), avec des écarts de précision plus ou moins marqués selon les spécifications.

7) Conclusion

L'analyse menée sur la série mensuelle des ventes de véhicules aux États-Unis entre 2006 et 2025 montre que cette série est fortement liée à la conjoncture économique. Les différentes étapes de l'étude ont mis en évidence une série à la fois instable et marquée par plusieurs ruptures, notamment lors de la crise financière de 2008-2009, du choc sanitaire de 2020, puis des difficultés rencontrées par le secteur automobile à partir de 2021. L'étude des points atypiques a confirmé cette sensibilité, tandis que les analyses graphiques et les tests statistiques ont montré l'existence d'une saisonnalité régulière, avec des variations qui reviennent selon les mois de l'année. La désaisonnalisation par la méthode X13-ARIMA-SEATS a ainsi permis de mieux isoler l'évolution propre de la série et de rendre sa lecture plus claire.

Dans un second temps, plusieurs modèles de prévision ont été comparés. Les résultats montrent que le meilleur modèle dépend du critère retenu : le SARIMA(3,1,1)(0,1,2)₁₂ présente les AIC et AICc les plus faibles, ce qui traduit un bon ajustement aux données passées. En revanche, sur la période de test, c'est le modèle STL qui prévoit le mieux, avec la MSE la plus faible et le R²OOS le plus élevé. Les modèles ETS et TBATS obtiennent aussi de bonnes performances en prévision, même s'ils sont moins bien classés selon les critères d'ajustement. Cela montre qu'un modèle bien ajusté n'est pas forcément celui qui prévoit le mieux. Enfin, le test de Diebold-Mariano indique que les modèles étudiés sont globalement plus précis que le modèle de référence AR(1).


Au final, ce travail montre qu'en matière de prévision, le modèle le plus complexe n'est pas forcément le plus efficace. Dans notre cas, les modèles les plus convaincants sont surtout ceux qui parviennent à bien capter la saisonnalité tout en restant adaptés au comportement réel de la série.

Pour prolonger cette étude, une première piste d'amélioration serait de combiner les prévisions issues de plusieurs modèles. En effet, les résultats montrent que certains modèles, comme STL, ETS et TBATS, obtiennent des performances assez proches. Plutôt que de retenir un seul modèle, il pourrait donc être intéressant de construire une prévision combinée, par exemple en faisant une moyenne des prévisions ou en pondérant les modèles selon leur qualité prédictive. Cette approche permettrait de réduire l'incertitude liée au choix d'un modèle unique et d'obtenir des prévisions plus robustes.


Une seconde piste serait d'intégrer des variables explicatives dans l'analyse, comme les taux d'intérêt, le prix du carburant, le revenu des ménages, les conditions de crédit ou encore la confiance des consommateurs. Cela permettrait de passer de modèles uniquement fondés sur l'historique des ventes à des modèles de type ARX ou ARMAX, capables de mieux prendre en compte les facteurs économiques qui influencent les achats de véhicules.

8) Annexes

Graphique 3 : Série originale et corrigée avec identification des points atypiques



Graphique 5 : Évolution de la série corrigée des ventes de véhicules aux États-Unis



Graphique 6 : Décomposition additive de la série corrigée des ventes de véhicules aux États-Unis






Tableau 4 : Points atypiques détectés par le pré-ajustement X13-ARIMA-SEATS

Date	Type	t-stat
oct-08	LS	-5.780
juil-09	AO	3.900
mai-20	TC	-4.238
janv-21	TC	-3.898
juin-21	LS	-5.560


Graphique 8 et 9 : Décomposition de la série par la méthode X13-ARIMA-SEATS




Graphique 10 : Prévisions des ventes de véhicules aux États-Unis selon le modèle STS




Graphique 11 : Prévisions des ventes de véhicules aux États-Unis pour l'année 2025
(modèle de Holt-Winters saisonnier additif)




Graphique 12 : Prévisions des ventes de véhicules aux États-Unis pour l'année
2025 (modèle ETS(A.N.A))



Graphique 13 : Prévisions des ventes de véhicules aux États-Unis pour l'année 2025 (Modèle TBATS)



Graphique 14 : Prévisions des ventes de véhicules aux États-Unis pour l'année 2025 (modèle ADAM ETS)



Graphique 15 : Prévisions des ventes de véhicules aux États-Unis pour l'année 2025 (modèle ADAM ETS + ARIMA)

